MODERNIŲ DUOMENŲ BAZIŲ PAGRINDAI

2 NAMŲ DARBAS

PARENGĖ: KĘSTUTIS STANKEVIČIUS

2-AS NAMŲ DARBAS

- Duomenų ežero realizacija su Snowflake duomenų platforma
  - Susikurti nemokamą Snowflake paskyrą: https://snowflake.com
    - Pasirinkti Enterprise (AWS Cloud) ir regioną EU (Stockholm)
    - Pasirinkti, kad naudosite kaip duomenų ežerą ir darysite duomenų vizualizacijas
    - Pasirinkti, SQL ir Python arba ir kitus jeigu norite, bet būtinai SQL!
  - Darbas su SnowSQL ir prisijungimas per IDE, tarkime DBeaver su JDBC tvarkyklę
  - Įkelti savo struktūrizuotus ir nestruktūrizuotus duomenis į Snowflake duomenų saugyklą
  - CRUD užklausos su įkeltais duomenimis naudojant SnowFlake Web UI
  - Sukurti savo individualų Duomenų ežero sprendimą ir atvaizduoti rezultatus Dashboard aplinkoje
  - Reikia trumpai aprašyti visus namų darbo atlikimo etapus su paveikslais

APIE SNOWFLAKE

- Snowflake yra debesies pagrindu sukurta duomenų platforma su visiškai nauju SQL užklausų varikliu, kuris veikia tik debesyje.
- Snowflake yra programinė įranga kaip paslauga, bet naudojama analitikai, o ne OLTP duomenims saugoti.
- Snowflake duomenų platforma suteikia greitas, lanksčias ir lengvai naudojamas duomenų saugojimo, apdorojimo ir analizės parinktis.
- Iš pradžių sukurta naudojant „Amazon Web Services“ (AWS), „Snowflake“ taip pat pasiekiama „Google Cloud“ ir „Microsoft Azure“ debesyse.

APIE PARQUET IR ICEBERG

- Parquet – tai atvirojo kodo failo formatas, skirtas dirbti su sudėtingais ir dideliais duomenų kiekiais, kuris gali būti suspaustas, yra saugomas stulpeline forma ir turi savo metaduomenis.
- Iceberg – tai atvirojo kodo failo formatas, skirtas dirbti su dideliais duomenis naudojant SQL ir plačiai naudojamas duomenų ežeruose bei palaiko ACID transakcijas.
- Skirtingi duomenų varikliai (Spark“, „Trino“, „Flink“, „Presto“, „Hive“ ir „Impala“) gali saugiai tuo pačiu metu dirbti su tokiais failais kaip Parquet, Iceberg, todėl jie plačiai naudojami duomenų ežeruose ir Big data sprendimuose.

PAGRINDINIAI ŽINGSNIAI

1. Snowflake registravimas, SnowSQL ir JDBC konfigūravimas
2. Prisijungimas su Dbeaver ar kitu įrankiu į Snowflake
3. Struktūrizuotų ir **nestruktūrizuotų** duomenų importavimas į Snowflake
4. Snowflake panaudojimas su struktūrizuotais ir **nestruktūrizuotais** duomenimis
5. Sukurti savo individualų sprendimą su Snowflake ar kitaip panaudoti Snowflake
6. Sprendimo rezultatus atvaizduoti per Snowflake Dashboards aplinką

* Studentai / grupės turi įkelti skirtingus duomenis (3 ir 4 žingsniai) ir sukurti skirtingas užklausas (4 žingsnis). Pademonstruoti sukurtą sprendimą individualiai / grupėse per Dashboards.

PASTABOS

- Reikia susikurti Snowflake asmeninę paskyrą, kuri yra nemokama 30 dienų.
- Reikia panaudoti DBeaver ar kitą IDE, kad prisijungti į Snowflake su JDBC tvarkykle
- Reikia būtinai panaudoti **nestruktūrizuotus** duomenis ir juos struktūrizuoti
  - CSV yra struktūrizuotas failas, XML/JSON pusiau struktūrizuoti failai
  - TXT kratinys, LOG eilutės skirtingos, Email/Chat turinys, MP3, JPG ir panašiai yra nestruktūrizuoti failai
- Darbą galima daryti grupėje iki 3 studentų.
- Sprendimas turi būti individualus, kuris parodytų, kad namų darbas padarytas kitaip negu pavyzdžiuose. Galima panaudoti įvairias Snowflake galimybes, kurių yra labai daug arba sukurti savo API/Web programą panaudojant Snowflake funkcionalumą, tarkime paversti per API/WEB programą tam tikro nestruktūrizuoto failo duomenis į struktūrizuotus ar ištraukti iš jų kitą struktūrizuotą formatą.

ŠALTINIAI 1

- Snowflake nemokama 30d. paskyra:
  - https://snowflake.com
- Snowflake Repository:
  - https://docs.snowflake.com/en/user-guide/snowflake-client-repository
- Getting Started with SnowSQL:
  - https://quickstarts.snowflake.com/guide/getting_started_with_snowsql/index.html
- Getting Started with Unstructured Data:
  - https://quickstarts.snowflake.com/guide/getting_started_with_unstructured_data/

ŠALTINIAI 2

- Snowflake ODBC driver:
  - https://docs.snowflake.com/en/developer-guide/odbc/odbc-windows
- SnowSQL diegimas:
  - https://docs.snowflake.com/en/user-guide/snowsql
- SQL Workbench / DBeaver naudojimas su Snowflake:
  - https://www.cdata.com/kb/tech/snowflake-odbc-mysql-workbench.rst
  - https://hevodata.com/learn/dbeaver-snowflake/
- Snowflake Tutorial:
  - https://www.tutorialspoint.com/snowflake/index.htm